戴昕笛

吉林大学计算机科学与技术学院
daixd5520@gmail.com
19295378722
Github：github.com/daixd5520
可实习 6 个月以上，立即到岗

教育背景

吉林大学，计算机科学与技术，*硕士在读* 2024.09 - 至今

- 研究方向：大语言模型数据优化、高效微调算法、图神经网络

吉林大学，软件工程，*本科* 2020.09 - 2024.06

实习与项目经历

优刻得科技股份有限公司 (UCloud)，算法工程师 | *LLM 训推优化 & 国产卡适配* 2023.07 - 2024.04

- *大模型分布式训练智算平台*：面向大规模客户提供分布式训练服务，需统一调度同构/异构计算卡集群。编写 **DeepSpeed + Pipeline 并行**训练代码，调研并实现**断点续训**方案保障长周期训练的容错性；调研国产显卡软件栈并适配 ChatGLM、LLaMA 等主流模型，成功打通**异构集群统一调度**链路；
- *"识问"内部知识问答机器人*：针对公司内部文档学习路径冗长的痛点，构建企业级 **RAG** 系统。使用 **BGE-large** 对内部文档知识库进行向量化嵌入并存入 **Milvus** 向量数据库，对 **Qwen-14B** 进行 RAG 与问题分类方向的 **LoRA 微调**，结合 Reranker 重排增强检索质量。微调后回答正确率相比直接调用 GPT-3.5 API 提升 **9.5%**。

LLM 动态推理路由系统开发，核心开发者 | *LLM CoT 优化* 2025.06 - 2025.09

- 当前 LLM 在文本分类中存在 "推理盲区"，依赖表面词汇捷径而非深层逻辑；盲目对所有样本使用 CoT 计算开销大且冗余。受**认知双过程理论**启发，设计并实现 RICO 动态推理路由框架；
- 构建 **System 1**（直接预测）与 **System 2**（CoT+ 多数投票）双轨架构，基于**置信度**、**Margin**、**熵**进行加权动态路由，仅将高难度样本交由 System 2 处理；使用强教师 LLM 生成的 **CoT 数据蒸馏**微调目标模型；
- 在 **6 个**长短文本分类基准上实现最优精度-效率权衡，小参数模型性能**全面反超**更大参数量的 Vanilla LLM。

自研端侧大模型全链路训练架构，核心开发者 | *LLM 底层开发* 2025.10 - 2025.12

- 端侧设备资源受限，现有训练框架难以直接适配。从零主导设计轻量级全链路训练架构，集成 **DeepSpeed ZeRO** 显存优化与长文本 **RoPE 插值**扩展，完整打通**预训练 →SFT→RLHF** 生命周期；
- 成功实现 **0.6B** 参数级模型端侧高效微调，实验论证 "提取 **10%** 核心难样本可逼近全量数据 **98%** 推理性能" 的假设，为端侧大模型高效训练提供可行方案。

专业技能

框架与生态：PyTorch, DeepSpeed, vLLM, Transformers

系统与计算：CUDA Programming, 分布式训练 (DP/TP/PP), GPU 显存优化 (ZeRO), Docker, K8s

算法与微调：SFT Data Mining, PEFT, Prompt Engineering, RAG, CoT

英语水平：CET4 643, CET6 563

核心科研成果

ASPIRE: Hard Sample Mining for Supervised Fine-Tuning in LLMs 学生一作 · ICML · CCF-A · 在投

- **痛点**：SFT 数据中大量简单样本导致训练效率低下，模型容易过拟合于易分类样本而忽略决策边界附近的困难模式；
- **方法**：提出双策略困难样本挖掘框架——ASPIRE-S 以 Reward Model 分差 ΔS 课程化排序；ASPIRE-D 依跨相邻 Epoch 训练 Loss 动态加权，精准量化样本难度，无需人工启发式规则；
- **成果**：在 Dolly/Alpaca/Wizard 上微调 LLaMA-2 & Gemma-2，超越全量微调基线；在 108M 轻量 RM 下保持高鲁棒性。

SimSFT: A Simple Data Augmentation for SFT in LLMs 学生一作 · SIGIR · CCF-A · 在投

- **痛点**：LLM 存在 "逆向诅咒" 问题（学会 "A 是 B" 却无法推出 "B 是 A"），现有 SFT 数据增强依赖高成本标注或外部模型；
- **方法**：将 SFT 数据的 Instruction 与 Response 互换并添加逆向 Prompt，零成本构建双向推理训练数据，让模型在前向与逆向数据上联合微调；
- **成果**：在 Gemma2-2B 和 LLaMA-2 上验证，GSM8K、HumanEval 等 6 个基准显著优于全量数据微调及其他增强基线，有效缓解逆向诅咒。

HOLA: Hyperbolic Low-Rank Adaptation for Graph Transfer Learning 学生一作 · ICML · CCF-A · 在投

- **痛点**：现有图迁移学习在欧氏空间下会严重扭曲图数据的层级结构，且 LoRA 直接应用于双曲流形会破坏几何约束；
- **方法**：在切空间执行 LoRA 低秩更新，引入**时间重构算子**显式修复双曲几何自洽性，结合 MMD 损失跨域特征对齐，首次从数学上解决 PEFT 与双曲流形的不兼容难题；
- **成果**：以低于 1% 的参数增量始终超越欧氏空间 SOTA 基线，大幅缓解拓扑偏差引起的负迁移。